

راهکارهای ارزیابی مدل

سنجه‌ها

برای یک مجموعه نقاط داده شده $\{x(1), \dots, x(m)\}$ ، که در آن هر $x(i)$ دارای n ویژگی است که به مجموعه‌ای از خروجی‌های $\{y(1), \dots, y(m)\}$ مرتبط هستند، هدف ارزیابی یک «دسته‌بند» (Classifier) است که چگونگی پیش‌بینی y بر اساس x را می‌آموزد.

دسته‌بندی

در این قسمت، سنجه‌های کلیدی ارائه شده‌اند که برای ارزیابی کارایی مدل در زمینه دسته‌بندی دودویی حائز اهمیت هستند.

ماتریس درهم‌ریختگی

«ماتریس درهم‌ریختگی» (Confusion Matrix) به منظور ارائه تصویری کامل هنگام ارزیابی کارایی مدل، مورد استفاده قرار می‌گیرد. این ماتریس به شکل زیر تعریف می‌شود:

		کلاس پیش‌بینی شده	
		+	-
کلاس واقعی	+	TP مثبت صحیح	FN منفی غلط خطای نوع دوم
	-	FP مثبت غلط خطای نوع اول	TN منفی صحیح

سنجه‌های کلیدی

سنجه‌های زیر معمولاً برای ارزیابی کارایی یک مدل دسته‌بندی مورد استفاده قرار می‌گیرند:

سنجه	فرمول	تفسیر
صحت (Accuracy)	$\frac{TP + TN}{TP + TN + FP + FN}$	کارایی کلی مدل
دقت (Precision)	$\frac{TP}{TP + FP}$	پیش‌بینی‌های مثبت چقدر صحیح هستند.
حساسیت صحت (Recall Sensitivity)	$\frac{TP}{TP + FN}$	پوشش نمونه‌های مثبت صحیح
ویژگی	$\frac{TN}{TN + FP}$	پوشش نمونه‌های منفی صحیح
امتیاز F1 (F1 Score)	$\frac{2TP}{2TP + FP + FN}$	سنجه ترکیبی مفید برای کلاس‌های نامتوازن

برای مشاهده دیگر «تقبل‌نامه‌های» مجله فرادرس، به [این لینک](#) مراجعه فرمایید.


منحنی مشخه عملکرد سیستم

«منحنی مشخصه عملکرد سیستم» (Receiver Operating Characteristic | ROC) نمودار TPR در مقابل FPR با تغییر دادن آستانه است. این سنجها در جدول زیر خلاصه شده‌اند.

معادل	فرمول	سنجه
حساسیت صحت	$\frac{TP}{TP + FN}$	نرخ مثبت صحیح (True Positive Rate)
۱-ویژگی (1-Specificity)	$\frac{FP}{TN + FP}$	نرخ مثبت غلط (False Positive Rate)

ناحیه زیر منحنی

ناحیه زیر منحنی مشخصه عملکرد سیستم، با عنوان AUC یا AUROC شناخته شده و ناحیه زیر نمودار ROC است که در تصاویر زیر نشان داده شده.



رگرسیون

در ادامه نکات کلیدی مورد نیاز در زمینه ارزیابی مدل‌های رگرسیون ارائه شده‌اند.

سنجه‌های کلیدی

برای یک مدل رگرسیون داده شده، سنجهای زیر معمولاً به منظور ارزیابی کارایی مدل مورد استفاده قرار می‌گیرند.

مجموع مربعات باقیمانده‌ها	مجموع مربعات توضیح داده شده	مجموع مربعات
$SS_{tot} = \sum_{i=1}^m (y_i - \bar{y})^2$	$SS_{reg} = \sum_{i=1}^m (f(x_i) - \bar{y})^2$	$SS_{RES} = \sum_{i=1}^m (y_i - f(x_i))^2$

ضریب تشخیص

ضریب تشخیص (Coefficient of Determination) که اغلب با عنوان R^2 یا r^2 به آن اشاره می‌شود، اندازه‌ای از اینکه خروجی‌های مشاهده شده چقدر خوب توسط مدل تکرار شده‌اند ارائه می‌کند و به صورت زیر تعریف می‌شود:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

سنجه‌های اصلی

سنجه‌هایی که در ادامه آمده‌اند معمولاً برای ارزیابی کارایی یک مدل رگرسیون با در نظر گرفتن n متغیر که در مدل دخیل می‌شوند، مورد استفاده قرار می‌گیرند.

Adjusted R^2	BIC	AIC	Mallow's C_p
$1 - \frac{(1 - R^2)(m - 1)}{m - n - 1}$	$\log(m)(n + 2) - 2\log(L)$	$2[(n + 2) - \log(L)]$	$\frac{SS_{res} + 2(n + 1)\hat{\sigma}^2}{m}$

که در آن L «درست‌نمایی» (likelihood) و $\hat{\sigma}^2$ تخمینی از واریانس مرتبط با متغیر پاسخ است.

انتخاب مدل

در ادامه، سنجه‌های مورد استفاده برای تعیین میزان داده‌های تست و آموزش در یادگیری نظارت شده ارائه شده‌اند.

واژگان

هنگام انتخاب یک مدل، ۳ بخش مختلف از داده‌ها از یکدیگر متمایز می‌شوند که به شرح زیر هستند:

مجموعه داده آموزش	مجموعه داده اعتبارسنجی	مجموعه داده تست
- مدل آموزش دیده - معمولاً ۸۰٪ از مجموعه داده	- مدل ارزیابی شده - معمولاً ۲۰٪ از مجموعه داده - مجموعه داده توسعه یا Hold-Out نیز نامیده می‌شود.	- مدل پیش‌بینی می‌کند - داده‌های دیده نشده

هنگامی که مدل انتخاب شد، براساس کل «مجموعه داده آموزش» مورد آموزش قرار می‌گیرد و روی یک «مجموعه داده دیده نشده» تست می‌شود. این مساله در تصویر زیر نشان داده شده است:




اعتبارسنجی متقابل

«اعتبارسنجی متقابل» (Cross Validation - CV) روش مورد استفاده برای انتخاب مدلی است که بیش از اندازه بر داده‌های آموزش تکیه ندارد. انواع متفاوت این نوع اعتبارسنجی در جدول زیر آورده شده‌اند:




Leave-p-Out	K-fold
- آموزش روی $n - p$ مشاهده و ارزیابی روی p تای باقیمانده انجام می‌شود. - شرایطی که $p = 1$ است، leave-one-out نامیده می‌شود.	- آموزش روی $k - 1$ لایه و ارزیابی روی لایه‌های باقیمانده - عموماً $k = 5$ یا 10 است.

متداول‌ترین روش مورد استفاده برای اعتبارسنجی متقابل k-fold نام دارد و مجموعه داده آموزش را به k لایه برای اعتبارسنجی مدل روی یک لایه تقسیم می‌کند، در حالیکه مدل روی $k-1$ لایه دیگر برای k مرتبه آموزش داده می‌شود. سپس، میانگین خطا برای k لایه محاسبه و به آن «خطای اعتبارسنجی متقابل» (Cross Validation Error) گفته می‌شود.



با قاعده‌سازی

هدف از فرآیند «با قاعده‌سازی» (Regularization) اجتناب مدل از «بیش‌برازش» (Overfit) داده‌ها است، بنابراین این فرآیند با مشکل واریانس بالا مقابله می‌کند. در جدول زیر برخی از انواع روش‌های رگرسیون مورد استفاده برای با قاعده‌سازی ارائه شده‌اند:

LASSO	Ridge	Elastic Net
ضریب را کاهش می‌دهد. برای انتخاب متغیر خوب است.	ضریب را کوچک‌تر می‌کند.	موازنه بین انتخاب متغیر و ضرایب کوچک
		
$\dots + \lambda \theta _1$ $\lambda \in \mathbb{R}$	$\dots + \lambda \theta _2^2$ $\lambda \in \mathbb{R}$	$\dots + \lambda \left[(1 - \alpha) \theta _1 + \alpha \theta _2^2 \right]$ $\lambda \in \mathbb{R}, \alpha \in [0, 1]$

انتخاب مدل

مدل با استفاده از مجموعه داده آموزش (Train Data Set)، مورد آموزش قرار می‌گیرد، سپس با مجموعه داده اعتبارسنجی (Validation Set) ارزیابی می‌شود، در ادامه مدل با بهترین کارایی روی مجموعه داده‌های ارزیابی انتخاب و در نهایت مدل روی کل مجموعه داده آموزش اعمال می‌شود.

تشخیص

در یادگیری ماشین از برخی روش‌ها به منظور تشخیص خطای مدل استفاده می‌شود. برخی از این موارد در ادامه بیان شده‌اند.

سوگیری







«سوگیری» (Bias) یک مدل، تفاوت بین پیش‌بینی مورد انتظار و مدل صحیحی است که کاربر تلاش می‌کند برای نقاط داده موجود پیش‌بینی کند.

واریانس

واریانس یک مدل در واقع پراکندگی پیش‌بینی‌های مدل برای نقاط داده ارائه شده است.

موازنه سوگیری/واریانس

هر چه مدل ساده‌تر باشد، سوگیری بالاتر و هر چه مدل پیچیده‌تر باشد، واریانس آن بالاتر است.

	کم‌برازش	برازش مناسب	بیش‌برازش
علائم	خطای یادگیری بالا خطای یادگیری نزدیک به خطای تست سوگیری بالا	خطای یادگیری اندکی کمتر از خطای تست است.	خطای آموزش کم خطای آموزش بسیار کمتر از خطای تست است. واریانس بالا
رگرسیون			
دسته‌بندی			
یادگیری عمیق			
درمان	پیچیده‌سازی مدل افزودن ویژگی‌های جدید آموزش طولانی‌تر		با قاعده‌سازی دریافت داده‌های بیشتر



تحلیل خطا

«تحلیل خطا» (Error Analysis)، تحلیل دلایل ریشه‌ای تفاوت در کارایی بین مدل کنونی و مدل کامل است. مدل کامل، مدلی است که بیشترین پارامترها را دارد.

تحلیل لغزش

«تحلیل لغزش» (Ablative Analysis)، تحلیل دلایل ریشه‌ای تفاوت در کارایی بین مدل کنونی و مدل پایه است. منظور از مدل پایه، مدلی است که کمترین پارامترها را دارد.

برای مشاهده دیگر «تقلب‌نامه‌های» مجله فرادرس، به [این لینک](#) مراجعه فرمایید.

جهت آگاهی از آخرین تقلب‌نامه‌ها منتشر شده، در [کانال تلگرام](#) مجله فرادرس عضو شوید.

تهیه و تنظیم: [مجله فرادرس](#)

